Pontificia Universidad Javeriana



Primera Entrega de Proyecto Administración de Bases de Datos

Presentado a:

Andrés Oswaldo Calderón Romero, PhD.

Presentado por:

Luis Esteban Chaustre Garzón

Tomas Felipe Guerra Hernandez

Daniel Alfredo Vidal De Leon

Facultad de Ingeniería

Departamento de Ingeniería de Sistemas

Bogotá, D.C. 2026

Tabla de Contenido

1. Introducción..... 3

2. Plan de Implementación..... 3

2.1. Semana 1..... 3

2.2. Semana 2..... 4

2.3. Semana 3..... 5

2.4. Semana 4..... 6

3. Diccionario de Datos..... 7

4. Diagrama de Modelo de Datos NoSQL..... 9

5. Conclusiones Entrega 1..... 10

1. Introducción

El presente documento corresponde a la primera entrega del proyecto, cuyo propósito es establecer las bases técnicas y metodológicas para el desarrollo de una infraestructura de datos geoespaciales orientada a la identificación y evaluación del potencial de aprovechamiento de energía solar en las cubiertas de edificaciones ubicadas en los municipios priorizados por los Programas de Desarrollo con Enfoque Territorial (PDET) en Colombia. Esta iniciativa busca aprovechar fuentes de información geográfica abiertas para identificar construcciones, analizar sus características espaciales y estimar la superficie disponible para posibles instalaciones de sistemas fotovoltaicos, generando información de utilidad para la Unidad de Planeación Minero-Energética (UPME).

Durante esta primera etapa se definieron los lineamientos generales para la implementación del proyecto, incluyendo la planificación de actividades, la selección de las fuentes de información y el diseño de la infraestructura de almacenamiento. Se seleccionaron Google Open Buildings y GlobalBuilding Atlas como fuentes principales de información sobre edificaciones, complementadas con la cartografía oficial del DANE para delimitar los municipios PDET. Asimismo, se estableció MongoDB como sistema de gestión de bases de datos y se diseñó un modelo inicial que define la organización de la información y las relaciones entre las colecciones, proporcionando una base para las siguientes etapas de procesamiento y análisis.

2. Plan de Implementación

El proyecto de la UPME consiste en diseñar e implementar un flujo de trabajo de análisis geoespacial reproducible para estimar el potencial de energía solar en los tejados de edificaciones dentro de los municipios priorizados como territorios PDET en Colombia.

Para lograrlo utilizando tecnologías NoSQL y datasets abiertos, los pasos necesarios para realizar el plan de implementación de la semana 1 a la 4 se estructurará de la siguiente forma:

2.1. Semana 1

Durante esta semana se buscará establecer las bases necesarias para iniciar el desarrollo del proyecto, definiendo las actividades, herramientas y recursos que permitirán orientar su implementación. Para ello, se elaborará un plan de implementación en el que se establecerán los objetivos y entregables que deberán cumplirse en cada semana, con el propósito de organizar el trabajo, realizar un seguimiento adecuado del avance y garantizar el cumplimiento de los objetivos generales del proyecto.

Adicionalmente, se comenzará con el diseño de la infraestructura de datos, identificando y definiendo la información que será necesaria para el funcionamiento del sistema, así como la manera en que esta será almacenada, organizada y gestionada. Como parte de esta etapa, se llevará a cabo la selección de los datasets que se utilizarán durante el desarrollo, teniendo en cuenta su relevancia, disponibilidad y calidad para los objetivos planteados.

Finalmente, se definirá el uso de MongoDB como sistema de gestión de bases de datos, considerando sus características de escalabilidad, flexibilidad en el manejo de datos y capacidad para integrar consultas geoespaciales de manera eficiente. Esta elección permitirá establecer una estructura de almacenamiento adecuada para las necesidades del proyecto y facilitará futuras etapas de procesamiento, consulta y análisis de la información.

2.2. Semana 2

Durante la segunda semana se llevará a cabo la selección, integración y preparación de los conjuntos de datos geoespaciales que servirán como base para el desarrollo del proyecto. Se trabajará con Google Open Buildings y GlobalBuilding Atlas como fuentes de información sobre edificaciones, complementándolas con la cartografía oficial del DANE para identificar y delimitar los municipios PDET de Colombia.

Asimismo, se iniciará el proceso de tratamiento y depuración de los datos, mediante la identificación de registros incompletos, corrección de geometrías inválidas y normalización de los sistemas de referencia espacial. Finalmente, se avanzará en la configuración de la infraestructura en MongoDB, definiendo el modelo de almacenamiento en formato GeoJSON y los índices geoespaciales necesarios para facilitar las consultas, cruces de información y cálculos de áreas de tejados por municipio.

2.2.1. Obtención de Datos

Para el desarrollo del proyecto, se seleccionaron dos de los conjuntos de datos abiertos recomendados para la identificación de edificaciones, los cuales se integrarán con las fuentes oficiales de delimitación territorial:

- Google Open Buildings: Este conjunto de datos proporciona la detección masiva de edificaciones en América Latina y el Caribe, entre otras regiones. Distribuido bajo las licencias Creative Commons (CC BY-4.0) y ODbL v1.0, servirá como fuente primaria de polígonos de construcciones para la extracción del área de los tejados.
- GlobalBuilding Atlas: Desarrollado por la Universidad Técnica de Múnich (TUM), comprende modelos de edificaciones con una resolución espacial de 3×3 metros. Está distribuido bajo la licencia MIT con restricción de cláusula de comuna y aportará la información geométrica 3D para evaluar la factibilidad estructural en las imágenes satelitales.
- Límites Territoriales y Municipios PDET: Se utilizará el Marco Geoestadístico Nacional (MGN) proporcionado por el DANE para extraer la cartografía municipal oficial de Colombia. Esta capa cartográfica está pensada para filtrar exclusivamente las jurisdicciones priorizadas como municipios PDET, conforme a los lineamientos de la Agencia de Renovación del Territorio.

Estrategia de integración de datos: Mediante la infraestructura de la base de datos NoSQL, se cruzará la información geoespacial de las edificaciones (Google Open Buildings y GlobalBuilding Atlas) con los polígonos de los municipios PDET. Este flujo procesará y agregará eficientemente la cantidad total de edificaciones y la superficie útil acumulada de tejados (*rooftops*) por municipio.

2.2.2. Tratamiento y Calidad de Datos

Durante esta fase se implementará un protocolo de depuración y validación geoespacial para garantizar la integridad de las fuentes antes del almacenamiento masivo:

- Limpieza y Filtrado: Identificación y gestión de registros nulos, geometrías corruptas o polígonos inválidos en los *datasets* de huellas de edificaciones.
- Normalización Formato-Espacial: Estandarización del sistema de referencia de coordenadas (CRS/SRID) y validación de la topología de los polígonos para asegurar operaciones de cruce precisas.
- Carga Masiva Optimizada: Configuración de técnicas de ingesta por lotes (*batch loading*) orientadas a optimizar el tiempo de procesamiento y el uso de memoria.

2.2.3. Integración Espacial en NoSQL y Modelado

Para cumplir con los requerimientos de la UPME sobre escalabilidad y análisis geoespacial NoSQL, la infraestructura se soportará en MongoDB:

- Indexación Geoespacial: Configuración de índices espaciales de tipo 2dsphere tanto en la colección de municipios como en la de edificaciones, optimizando los tiempos de respuesta de las consultas de contención e intersección ($geoIntersects, $geoWithin).
- Diccionario de Datos: Documentación detallada del esquema en formato GeoJSON, especificando tipos de datos, atributos clave (como codigo_dane, area_m2, fuente) e índices requeridos.

2.3. Semana 3

Durante la tercera semana se realizará la preparación, optimización y carga de los conjuntos de datos en MongoDB. Para ello, se estandarizarán las geometrías de Google Open Buildings y GlobalBuilding Atlas al formato GeoJSON, se validarán los registros para eliminar datos duplicados o geometrías inválidas y se configurarán los índices geoespaciales necesarios para optimizar las consultas espaciales.

Debido al gran volumen de información, se implementarán mecanismos de carga por lotes y procesamiento paralelo que permita almacenar los datos de manera eficiente, evitando problemas de memoria y tiempos excesivos de ejecución. Finalmente, se desarrollará un análisis exploratorio preliminar para comparar ambos conjuntos de datos, considerando la cantidad de edificaciones identificadas, la distribución de las áreas de los tejados y las diferencias de cobertura en los municipios PDET.

2.3.1. Aplicación de Requisitos Previos e Indexación Espacial

Para cumplir con los requerimientos técnicos y mantener la consistencia con el entregable anterior, se aplicarán los siguientes procesos a los dos datasets seleccionados (*Google Open Buildings* y *GlobalBuilding Atlas*):

- Estandarización de Geometrías: Conversión y validación de todos los polígonos de huellas de edificaciones al formato estándar GeoJSON (Polígonos / MultiPolígonos).

- Indexación Espacial (2dsphere): Creación de índices espaciales en la base de datos NoSQL para ambas colecciones de edificaciones. Esto es indispensable para agilizar drásticamente las consultas de intersección geométrica con los polígonos de los municipios PDET.
- Validación de Integridad: Filtro y eliminación de geometrías mal formadas o duplicadas provenientes de las fuentes abiertas antes de su almacenamiento definitivo.

2.3.2. Eficiencia en la Carga de Datos

Debido al enorme volumen de registros que manejan estos datasets masivos (millones de polígonos geointeligentes), la carga directa tradicional causaría desbordamientos de memoria o tiempos de ejecución inaceptables. Para solucionar esto, se implementarán las siguientes técnicas de optimización:

- Carga por Lotes (*Batch Loading*): Ingesta de los datos en bloques estructurados (por ejemplo, lotes de 10,000 a 50,000 documentos) para optimizar el uso de la memoria RAM y reducir la sobrecarga de red en el servidor NoSQL.
- Procesamiento Paralelo: División de los archivos masivos por zonas geográficas o departamentos para permitir ejecuciones concurrentes de carga mediante scripts automatizados.
- Inserciones Masivas Optimizadas (Bulk Operations): Uso de comandos de escritura masiva desordenada (*unordered bulk inserts*) en MongoDB para maximizar la velocidad de inserción al omitir validaciones innecesarias de orden secuencial en lotes masivos.

2.3.3. Análisis Exploratorio de Datos Preliminar

Con el fin de comprender las características principales de los datos cargados y comparar ambas fuentes, se realizará un EDA inicial que destacan las siguientes métricas clave:

- Conteo Total de Edificaciones: Volumen total de huellas de edificios detectadas por municipio PDET para cada dataset (*Google Open Buildings* vs. *GlobalBuilding Atlas*).
- Distribución de Áreas de Tejados (*Rooftops*): Estadísticas descriptivas del área superficial de las edificaciones (área mínima, máxima, promedio y mediana en metros cuadrados) para evaluar la viabilidad de instalación de paneles solares.
- Comparativa de Cobertura: Análisis de las diferencias de densidad y detección entre los polígonos 2D de Google y los modelos 3D de la Universidad Técnica de Múnich (TUM) en las zonas rurales y urbanas priorizadas de los territorios PDET.

2.4. Semana 4

En esta semana se cumplirá el propósito principal del proyecto, utilizando los datasets integrados y la infraestructura NoSQL previamente configurada para resolver las necesidades de la UPME. El desarrollo se dividirá en dos componentes clave:

2.4.1. Flujo de Trabajo de Análisis Geoespacial (Conteo y Área de Tejados):

- Mediante consultas espaciales en MongoDB, se ejecutarán los cruces entre los polígonos de los municipios PDET y las edificaciones de los datasets seleccionados.
- Se calculará y estimará el número total de edificaciones y la superficie acumulada de los tejados (*rooftops*) por cada territorio evaluado.
- Se presentarán los resultados estructurados utilizando tablas de datos y visualizaciones cartográficas adecuadas.

2.4.2. Reporte Técnico Final

Durante esta semana se llevará a cabo la elaboración de un informe técnico integral que recopilará y documentará el trabajo realizado a lo largo de las cuatro semanas de desarrollo del proyecto. Este documento presentará de manera estructurada las diferentes etapas de implementación, desde la selección y preparación de los conjuntos de datos hasta su integración en la infraestructura de MongoDB y el análisis de la información geoespacial obtenida.

Asimismo, se expondrán los resultados alcanzados mediante tablas, gráficos y visualizaciones que permitan comprender los hallazgos y evaluar el cumplimiento de los objetivos planteados. Se incluirá también una discusión sobre los resultados, las dificultades técnicas encontradas durante el desarrollo y las soluciones implementadas. Finalmente, se formularán conclusiones y recomendaciones estratégicas dirigidas a la UPME, orientadas a identificar oportunidades de mejora y posibles aplicaciones de la información obtenida para la evaluación del potencial de aprovechamiento de energía solar en los municipios PDET.

3. Diccionario de Datos

El diccionario de datos presentado en la Tabla 1 describe de manera resumida la estructura de la base de datos diseñada para almacenar, organizar y analizar la información geoespacial de las edificaciones ubicadas en los municipios PDET de Colombia, el diccionario de datos completo se puede consultar en el repositorio de GitHub del equipo: https://github.com/TFelipe3454/Proyecto-Administraci-n-de-Bases-de-Datos. La estructura se encuentra organizada en seis colecciones dentro de MongoDB, cada una con una función específica dentro del proceso de almacenamiento y análisis de la información. La colección municipios_pdet contiene la identificación y delimitación geográfica de los municipios, utilizando el código DANE como identificador principal y geometrías GeoJSON para representar sus límites territoriales.

Colección: municipios_pdet			
Atributo	Tipo de dato	Descripción	Clave
codigo_dane	String	Código DANE que identifica al municipio.	PK
nombre	String	Nombre oficial del municipio.	
departamento_codigo	String	Código DANE del departamento.	
departamento_nombre	String	Nombre del departamento.	
subregion_pdet	String	Subregión PDET a la que pertenece el municipio.	

geometria	GeoJSON Polygon/MultiPolygon	Delimitación geográfica oficial del municipio.	
Colección: lotes_carga			
Atributo	Tipo de dato	Descripción	Clave
id	ObjectId	Identificador del lote de carga.	PK
fuente	String	Fuente de los datos cargados.	
archivo	String	Nombre del archivo procesado.	
n_leidos	Integer	Cantidad de registros leídos.	
n_insertados	Integer	Cantidad de registros almacenados.	
n_rechazados	Integer	Cantidad de registros descartados por errores.	
fecha_carga	Date	Fecha y hora de la carga.	
Colección: edificaciones_google			
Atributo	Tipo de dato	Descripción	Clave
id	ObjectId	Identificador de la edificación.	PK
codigo_dane	String	Municipio al que pertenece la edificación.	FK
lote_id	ObjectId	Lote de carga del que proviene el registro.	FK
geometria	GeoJSON Polygon	Huella geográfica de la edificación.	
centroide	GeoJSON Point	Centro geométrico de la edificación.	
area	Double	Área de la huella en metros cuadrados.	
area_fuente	Double	Área reportada por Google, en metros cuadrados.	
confianza	Double	Puntaje de confianza de la detección.	
Colección: edificaciones_gba			
Atributo	Tipo de dato	Descripción	Clave
id	ObjectId	Identificador de la edificación.	PK
codigo_dane	String	Municipio al que pertenece la edificación.	FK
lote_id	ObjectId	Lote de carga del que proviene el registro.	FK
geometria	GeoJSON Polygon	Huella geográfica de la edificación.	
centroide	GeoJSON Point	Centro geométrico de la edificación.	
area	Double	Área de la huella en metros cuadrados.	
altura	Double	Altura estimada de la edificación, en metros.	
Colección: ejecuciones_analisis			
Atributo	Tipo de dato	Descripción	Clave
id	ObjectId	Identificador de la ejecución del análisis.	PK
fuente	String	Fuente de edificaciones analizada.	
fecha_ejecucion	Date	Fecha y hora de ejecución.	
area_min	Double	Área mínima requerida para considerar apta una edificación.	
Colección: resumen_municipal			
Atributo	Tipo de dato	Descripción	Clave
id	ObjectId	Identificador del resumen.	PK
codigo_dane	String	Municipio al que corresponde el resumen.	FK
ejecucion_id	ObjectId	Ejecución del análisis que generó el resumen.	FK
fuente	String	Fuente de edificaciones analizada.	
n_edificaciones	Integer	Total de edificaciones identificadas en el municipio.	
n_aptas	Integer	Cantidad de edificaciones que cumplen los criterios establecidos.	

area_total	Double	Área total de las huellas de edificaciones, en m².	
area_apta	Double	Área acumulada de las edificaciones aptas, en m².	

Tabla 1. Versión resumida del Diccionario de Datos. Elaboración Propia.

Por otra parte, las colecciones edificaciones_google y edificaciones_gba almacenan las huellas geográficas de las edificaciones provenientes de Google Open Buildings y GlobalBuilding Atlas, respectivamente. Ambas contienen atributos relacionados con la ubicación, geometría y superficie de las construcciones, mientras que cada una conserva características particulares de su fuente, como el nivel de confianza de las detecciones de Google o la altura estimada proporcionada por GlobalBuilding Atlas. Adicionalmente, la colección lotes_carga permite realizar el seguimiento de los procesos de importación, registrando la cantidad de documentos procesados, insertados y rechazados.

Finalmente, las colecciones ejecuciones_analisis y resumen_municipal permiten almacenar los parámetros y resultados de los análisis realizados. La primera registra las condiciones bajo las cuales se ejecuta cada evaluación, mientras que la segunda consolida los principales indicadores por municipio y fuente de información, incluyendo el número total de edificaciones, la cantidad de construcciones que cumplen los criterios establecidos y sus respectivas áreas acumuladas. En conjunto, esta estructura permite mantener la trazabilidad de los datos, facilitar las consultas geoespaciales y generar resultados comparables que contribuyan a la evaluación del potencial de aprovechamiento de energía solar en los territorios PDET.

4. Diagrama de Modelo de Datos NoSQL

La Figura 1 presenta el modelo de datos propuesto para la organización y gestión de la información geoespacial en MongoDB, junto con las relaciones establecidas entre las seis colecciones que lo conforman. El modelo contempla una estructura centralizada alrededor de la colección municipios_pdet, que se relaciona con las dos colecciones de edificaciones mediante el atributo codigo_dane. De esta manera, cada edificación puede asociarse con su respectiva jurisdicción territorial. Por otra parte, las colecciones edificaciones_google y edificaciones_gba mantienen una estructura independiente, lo que permite conservar las particularidades de cada fuente de información y realizar análisis comparativos sin mezclar sus registros.

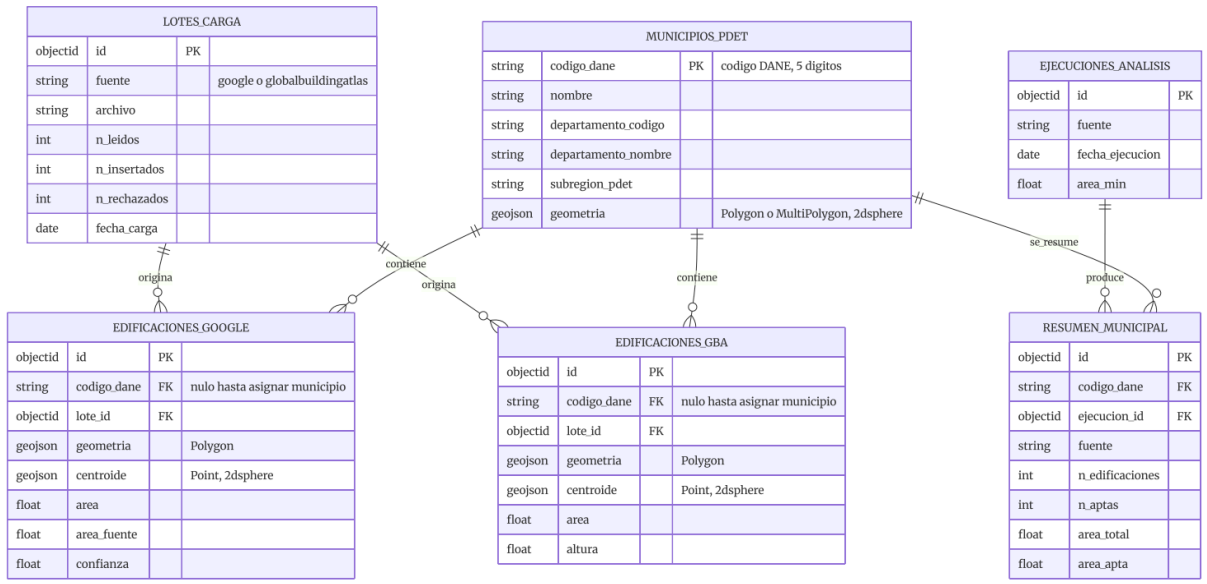


Figura 1. Diagrama de Modelo de Datos NoSQL

Adicionalmente, el modelo incorpora la colección lotes_carga, relacionada con ambas colecciones de edificaciones, con el propósito de mantener la trazabilidad del origen de los registros y de los procesos de importación. Esto permite identificar el lote del cual proviene cada edificación y consultar el estado de las operaciones de carga. Asimismo, se incluye la colección ejecuciones_analisis, que se relaciona con resumen_municipal para asociar los resultados obtenidos con la ejecución que los generó, permitiendo conservar un historial de los análisis realizados y sus respectivos parámetros.

Finalmente, las relaciones entre las colecciones se establecen mediante identificadores y referencias lógicas, representadas en el diagrama a través de las claves primarias y foráneas. Esta organización permite separar los datos originales, la información territorial, los procesos de carga y los resultados analíticos, facilitando su administración y consulta. De esta forma, el modelo proporciona una estructura organizada y escalable para realizar operaciones de integración geoespacial y consolidar indicadores sobre las edificaciones identificadas en los municipios PDET.

5. Conclusiones Entrega 1

La primera etapa del proyecto permitió establecer una planificación de trabajo y definir los principales componentes técnicos necesarios para su desarrollo. La selección de Google Open Buildings y GlobalBuilding Atlas, junto con la información territorial proporcionada por el DANE, constituye una base adecuada para identificar edificaciones y relacionarlas con los municipios PDET. Además, la elección de MongoDB responde a la necesidad de gestionar grandes volúmenes de información geoespacial y realizar consultas eficientes sobre las geometrías almacenadas.

Por otra parte, el diseño del modelo de datos permitió establecer una estructura organizada para almacenar la información territorial, las edificaciones, los procesos de carga y los resultados de los análisis. Aunque todavía es necesario desarrollar los procesos de depuración, integración y validación de los conjuntos de datos, esta primera entrega

proporciona los fundamentos técnicos y metodológicos para continuar con su implementación. De esta manera, se avanza hacia la construcción de una infraestructura que permita identificar oportunidades de aprovechamiento de energía solar en los territorios priorizados y generar información relevante para la planeación energética de la UPME.