Pontificia Universidad Javeriana



Segunda Entrega de Proyecto Administración de Bases de Datos

Presentado a:

Andrés Oswaldo Calderón Romero, PhD.

Presentado por:

Luis Esteban Chaustre Garzón

Tomas Felipe Guerra Hernandez

Daniel Alfredo Vidal De Leon

Santiago Beltran

Andres Jacobo Urrea

Facultad de Ingeniería

Departamento de Ingeniería de Sistemas

Bogotá, D.C. 2026

Tabla de Contenido

1. Introducción..... 3

2. Adquisición de los datos y verificación..... 3

2.1. Google Open Buildings..... 3

2.2. Global Building Atlas..... 4

3. Integridad de los datos y formato..... 6

3.1. Google Open Buildings..... 6

3.2. Global Building Atlas..... 7

4. Integración espacial NoSQL municipios PDET..... 8

5. Conclusiones Entrega 2..... 12

1. Introducción

El presente documento describe la integración, verificación y control de calidad de los datos geoespaciales del proyecto, cuyo propósito es analizar la infraestructura y las huellas de edificaciones en los 170 municipios priorizados por los Programas de Desarrollo con Enfoque Territorial (PDET) de Colombia. La delimitación de estos municipios se construye a partir del Marco Geoestadístico Nacional (MGN) del DANE, y las edificaciones provienen de dos conjuntos de datos abiertos: Google Open Buildings y GlobalBuildingAtlas. Dado que los tres conjuntos son de gran tamaño, el trabajo se orientó a reducirlos desde el inicio a la zona de estudio, de modo que solo se almacene y procese la información pertinente.

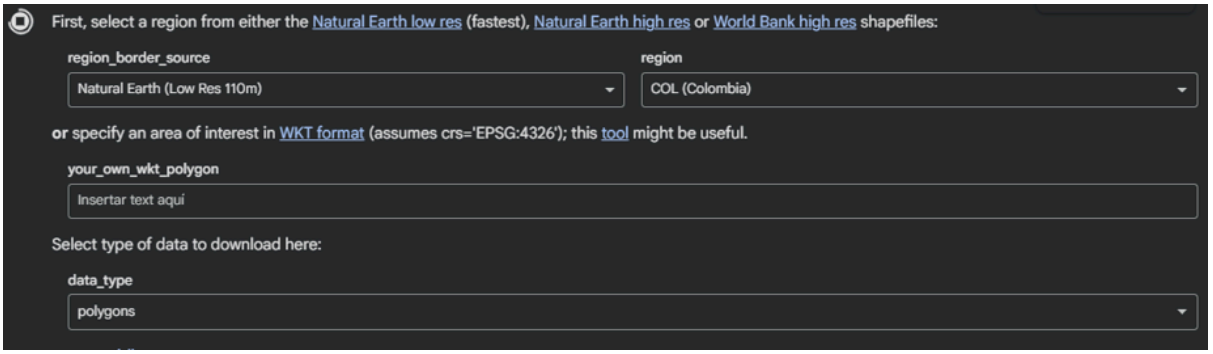
El desarrollo del entregable sigue tres etapas consecutivas. La primera es la adquisición y verificación de las fuentes primarias, que documenta cómo se obtuvo cada conjunto de datos y cómo se restringió a los municipios PDET. La segunda es la auditoría de integridad y formato, en la que se comprobó que las geometrías cumplieran el estándar GeoJSON requerido por MongoDB, con coordenadas en el sistema de referencia WGS 84 (EPSG:4326), y se revisó la presencia de valores nulos o inválidos. La tercera es la integración espacial en MongoDB, donde se cargaron los límites municipales y se crearon los índices que permiten consultarlos de forma eficiente, entre ellos un índice de tipo 2dsphere.

Las superficies de las edificaciones se calcularán en etapas posteriores sobre la proyección local MAGNA-SIRGAS (EPSG:9377), que ofrece áreas en metros cuadrados. Este entregable deja los datos preparados para esa fase y para la asignación de edificaciones a municipios. El cumplimiento de estos estándares garantiza la consistencia, limpieza y disponibilidad de los datos requeridos para las siguientes fases del proyecto.

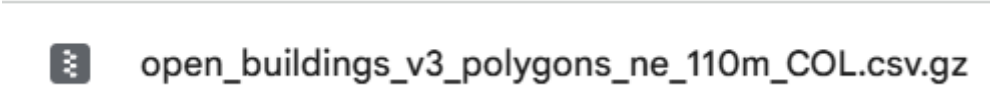
2. Adquisición de los datos y verificación

2.1. Google Open Buildings

Para la adquisición de los datos, se emplearon los enlaces oficiales provistos en la documentación del proyecto. El primer conjunto de datos corresponde a Google Open Buildings; dado el gran volumen de información que abarca el dataset global, su descarga íntegra resulta inviable. No obstante, mediante el cuaderno de Google Colab integrado en la plataforma oficial, fue posible aislar y extraer exclusivamente el subconjunto geográfico correspondiente a Colombia, tal como se ilustra en la siguiente imagen:

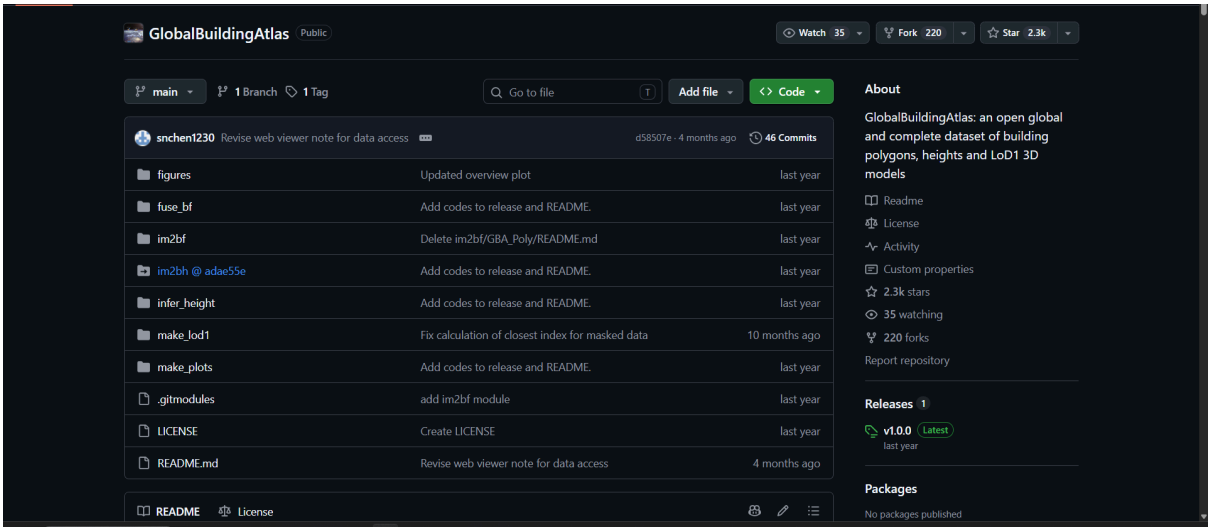


Como resultado de este proceso, se obtiene un archivo comprimido bajo la nomenclatura: open_buildings_v3_polygons_ne_110m_COL.csv.gz El cual se almacena automáticamente en el espacio de OneDrive asociado a la cuenta que ejecuta el cuaderno de Google Colab, conforme se evidencia a continuación:

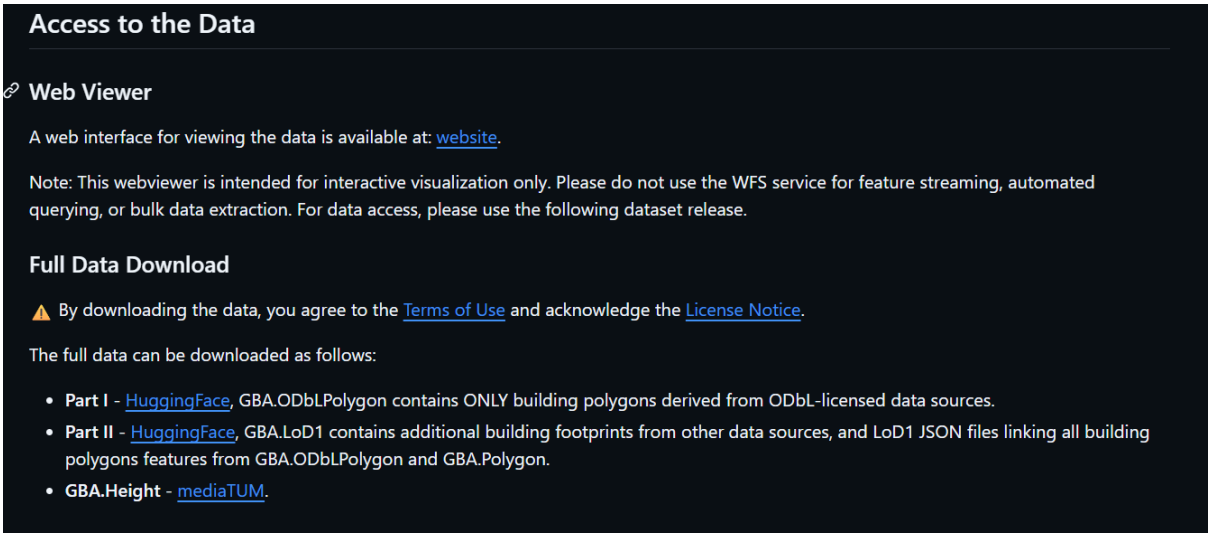


2.2. Global Building Atlas

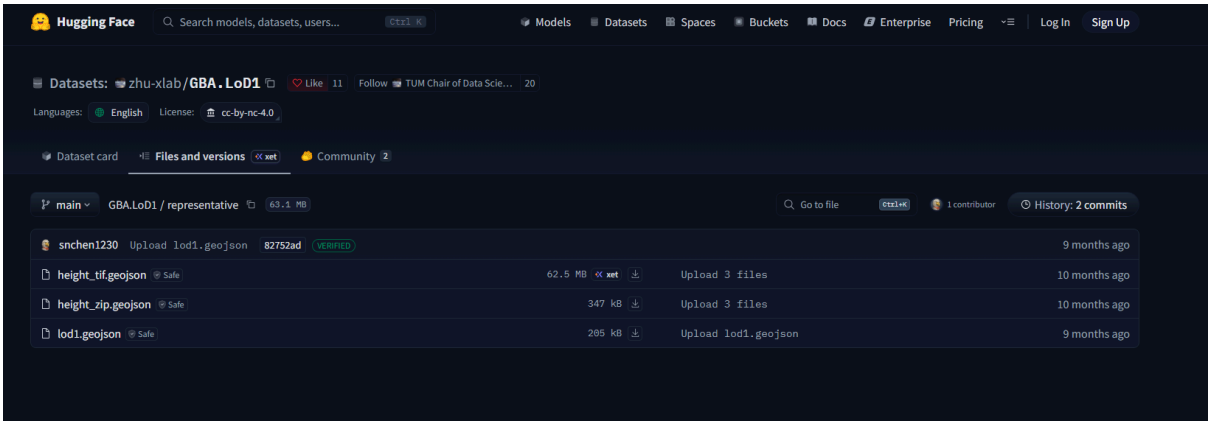
Este dataset a diferencia del primero no lo podremos obtener tan sencillamente ya que no posee una forma tan simple para filtrar todo el dataset por lo que deberemos juguetear para obtener lo que queremos. Empezaremos entrando en el Github del dataset como se ve a continuación:



Ya dentro del dataset nos dirigimos al archivo README.md y ahí bajamos hasta la sección de Acces to the Data.



Como se puede ver en la imagen para acceder a los datos se debe ingresar a los links de una página llamada HuggingFace, ingresamos a dicha página.



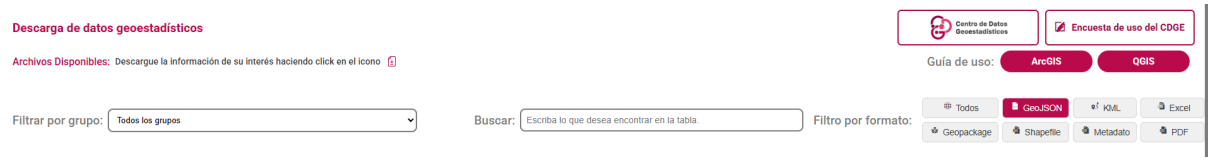
Dentro de dicha página se nos presentan 3 datasets distintos más sin embargo para el propósito de este proyecto solo necesitamos 1 el cual es el de lod1.geojson ya que estos contienen las teselas o mallas geográficas globales que estructuran el área de estudio. Los otros datasets fueron descartados ya que nos muestran información sobre la altura de los edificios lo cual no es necesario para nuestro proyecto.

Para poder usar esos datos es necesario filtrar los municipios PDET reconocidos por el DANE usando el siguiente enlace:

https://www.renovacionterritorio.gov.co/central-pdet/que-son-los-pdet

Nos dirigimos a esta parte de la página y descargamos el Excel que contiene todos los municipios designados como PDET. Luego fue necesario buscar los datos GeoJSON de todos los municipios de Colombia, para eso nos dirigimos al siguiente link: https://geoportal.dane.gov.co/servicios/descarga-y-metadatos/datos-geoestadisticos/?cod=111

Ya dentro de la página filtramos los datasets a la derecha con los que son GeoJSON como se ve en la imagen y lo descargamos.



Después buscamos el dataset y lo descargamos el dataset que tiene todos los municipios de Colombia el cual es el siguiente.

Documento	Versión	Formato	Tamaño del archivo	Acción
Versión MGN2025-Nivel Dirección	2025	GeoJSON	80 MB	Descargar
Versión MGN2025-Nivel Clase	2025	GeoJSON	80 MB	Descargar
Versión MGN2025-Nivel Manzana censal	2025	GeoJSON	80 MB	Descargar
Versión MGN2025-Nivel Sección urbano	2025	GeoJSON	80 MB	Descargar
Versión MGN2025-Nivel Sector urbano	2025	GeoJSON	80 MB	Descargar
Versión MGN2025-Nivel Area censal urbana (cabeceras y centros poblados)	2025	GeoJSON	80 MB	Descargar
Versión MGN2025-Nivel Departamento	2025	GeoJSON	80 MB	Descargar
Versión MGN2025-Nivel Municipio	2025	GeoJSON	80 MB	Descargar
Versión MGN2025-Nivel Sección rural	2025	GeoJSON	80 MB	Descargar
Versión MGN2025-Nivel Sector rural	2025	GeoJSON	80 MB	Descargar

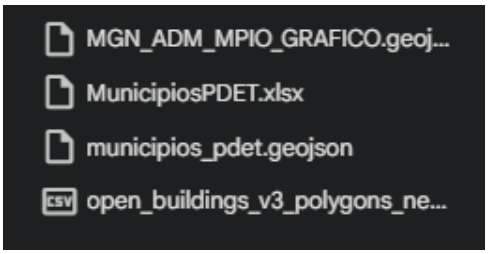
Como se va a mostrar posteriormente en el informe, con estos datos es posible hacer cruces para filtrar los municipios PDET para hacer una limpieza de los datos.

3. Integridad de los datos y formato

Es indispensable realizar una limpieza exhaustiva de los datos para garantizar su utilidad y compatibilidad con la base de datos de MongoDB. Para ello, es necesario verificar que las geometrías GeoJSON cumplan estrictamente con el formato requerido para su almacenamiento y consulta espacial, así como identificar la presencia de valores nulos con el fin de evaluar si deben ser depurados o imputados mediante técnicas acordes a cada situación. Para esto usamos 2 cuadernos de Google Colab para cerciorarse de que los datos cumplen con lo estipulado.

3.1. Google Open Buildings

Para auditar la integridad de los datos de Google Open Buildings, se utilizó el cuaderno de Google Colab titulado Data Integrity and Format GOB.ipynb. El propósito principal de este proceso fue verificar que las estructuras GeoJSON cumplieran con los estándares requeridos y preparar las geometrías para su posterior indexación espacial en MongoDB (2dsphere). Para filtrar fueron usados los siguientes archivos:



Una vez se corre la primera celda del cuaderno de Google Colab se obtienen los municipios PDET los cuales están en el formato deseado de 2dsphere.

```
-> Lote 160 procesado. Edificios retenidos en zona PDET: 24602
-> Lote 161 procesado. Edificios retenidos en zona PDET: 24552
-> Lote 162 procesado. Edificios retenidos en zona PDET: 24702
-> Lote 163 procesado. Edificios retenidos en zona PDET: 24455
-> Lote 164 procesado. Edificios retenidos en zona PDET: 24629
-> Lote 165 procesado. Edificios retenidos en zona PDET: 24245
-> Lote 166 procesado. Edificios retenidos en zona PDET: 7572

Registros originales analizados: 16530628
Edificios limpios confinados al Excel PDET (Listos para MongoDB 2dsphere): 2223614
```

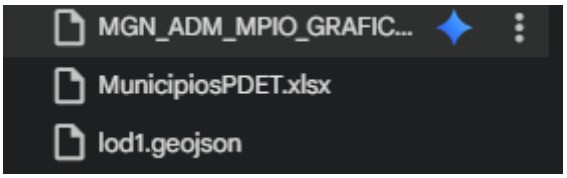
Como se puede observar de los 16.530.628 registros pertenecientes a Colombia, los relacionados a los municipios PDET los cuales están listos para su inserción en la base de datos son 2.223.614. Ahora veremos si en estos hay valores nulos o erróneos en los datasets.

```
================================================
INFORME DE AUDITORÍA Y CALIDAD DE DATOS (PDET)
================================================
Valores nulos por columna en el dataset final:
latitude            0
longitude           0
area_in_meters      0
confidence          0
geometry            0
full_plus_code      0
index_right         0
dpto_ccdgo          0
mpio_ccdgo          0
mpio_cdpmp          0
dpto_cnmbr          0
mpio_cnmbr          0
mpio_crslc          0
mpio_tipo           0
mpio_narea          0
mpio_nano           0
shape_Leng          0
shape_Area          0

Geometrías vacías (is_empty): 0
Geometrías inválidas remanentes: 0
Sistema de Referencia de Coordenadas (CRS): EPSG:4326
dtype general de muestra: float64
```

3.2. Global Building Atlas

Para este dataset fue necesario usar los siguientes archivos para filtrar la información:



Para optimizar el rendimiento y evitar sobrecargar los recursos de procesamiento, se implementó un filtro espacial preliminar utilizando la cuadrícula global de teselas y los límites administrativos de los 170 municipios PDET. A través de este proceso, se cruza el índice de teselas (disponible en formato GeoJSON) con los polígonos municipales oficiales del DANE (MGN 2025) mediante una operación de intersección espacial (sjoin). Esto permite aislar y seleccionar únicamente las celdas geográficas que intersectan con las zonas de estudio priorizadas, reduciendo drásticamente el volumen de datos a descargar y procesar en las siguientes fases del proceso.

Luego ejecutamos el segundo bloque de código usando el archivo anteriormente generado para buscar si tienen datos nulos o no válidos para el desarrollo del laboratorio.

```
=== REPORTE DE AUDITORÍA: MUNICIPIO / LOTE PDET_COLOMBIA ===
Total de registros iniciales: 170

-> [CRS] OK: Ya se encuentra en EPSG:4326.

Valores nulos por columna:
dpto_ccdgo          0
mpio_ccdgo          0
mpio_cdpmp          0
dpto_cnmbr          0
mpio_cnmbr          0
mpio_crslc          0
mpio_tipo           0
mpio_narea          0
mpio_nano           0
shape_Leng          0
shape_Area          0
geometry            0
dtype: object

-> [Topología] OK: No se detectaron auto-intersecciones ni geometrías inválidas.

--- Resumen de Integridad ---
Registros válidos listos para MongoDB: 170
Registros descartados: 0
================================================
```

Con esto se demuestra que después de filtrar la información de ambos datasets sobre los municipios PDET en Colombia, estos no presentan ningún error de formato o datos nulos que sea necesario de tratar.

4. Integración espacial NoSQL municipios PDET

Para realizar una integración espacial inicial en MongoDB que contenga los datos de los municipios PDET, el primer paso consistió en obtener los límites geográficos de los municipios del país a partir del MGN del DANE. Desde el portal de descarga de datos geoestadísticos se filtró el grupo correspondiente al Marco Geoestadístico Nacional y el formato GeoJSON, y se descargó el archivo «Versión MGN2025-Nivel Municipio», de versión 2025 y con un tamaño de 80 MB (DANE, 2025).



Antes de utilizar el archivo se analizó su contenido con el script de Python inspeccion_mgn.py, que se puede encontrar en el repositorio de GitHub del equipo. El archivo contiene 1.122 registros, que corresponden a los municipios del país. Todas las

geometrías son de tipo MultiPolygon y el sistema de coordenadas es EPSG:4326. Los campos disponibles se muestran en la figura. De ellos se emplearon el código y el nombre del municipio y del departamento, además de la geometría. Esta inspección permitió confirmar que el archivo era adecuado para almacenarse en MongoDB, cuyo formato nativo de datos espaciales es GeoJSON.

```
PS C:\Users\Administrador\PUJ2630\DBA\datos_proyecto\scripts> python .\inspeccion_mgn.py

--- INFORMACIÓN GENERAL ---
Total de registros: 1122
Sistema de coordenadas: EPSG:4326
Tipos de geometría:
MultiPolygon    1122
Name: count, dtype: int64

--- CAMPOS DISPONIBLES ---
['dpto_ccdgo', 'mpio_ccdgo', 'mpio_cdpmp', 'dpto_cnmbr', 'mpio_cnmbr', 'mpio_crslc', 'mpio_tipo', 'mpio_narea', 'mpio_nano', 'shape_Leng', 'shape_Area', 'geometry']

--- PRIMEROS 5 MUNICIPIOS ---
  dpto_ccdgo mpio_ccdgo mpio_cdpmp dpto_cnmbr  mpio_cnmbr                     mpio_crslc  mpio_tipo  mpio_narea  mpio_nano  shape_Leng  shape_Area
0         05        001      05001  ANTIOQUIA    MEDELLÍN                           1965  MUNICIPIO  374.741484       2025    1.035380    0.030608
1         05        002      05002  ANTIOQUIA   ABEJORRAL                           1814  MUNICIPIO  506.959782       2024    1.158504    0.041384
2         05        004      05004  ANTIOQUIA    ABRIAQUÍ                           1912  MUNICIPIO  296.974188       2025    0.810667    0.024253
3         05        021      05021  ANTIOQUIA  ALEJANDRÍA  Decreto departamental 304 de 1907  MUNICIPIO  128.856431       2024    0.705200    0.010535
4         05        030      05030  ANTIOQUIA       AMAGÁ                           1912  MUNICIPIO   84.117145       2024    0.445533    0.006867
```

El archivo del DANE contiene todos los municipios del país, mientras que el proyecto requiere únicamente los municipios PDET. Para identificarlos se utilizó un archivo en Excel con el listado de estos municipios, organizado por subregión PDET, código y nombre del departamento y código y nombre del municipio.

Subregión PDET	Código DANE Departamento	Departamento	Código DANE Municipio	Municipio
ALTO PATÍA Y NORTE DEL CAUCA	19	CAUCA	19050	ARGELIA
ALTO PATÍA Y NORTE DEL CAUCA	19	CAUCA	19075	BALBOA
ALTO PATÍA Y NORTE DEL CAUCA	19	CAUCA	19110	BUENOS AIRES
ALTO PATÍA Y NORTE DEL CAUCA	19	CAUCA	19130	CAJIBÍO
ALTO PATÍA Y NORTE DEL CAUCA	19	CAUCA	19137	CALDONO
ALTO PATÍA Y NORTE DEL CAUCA	19	CAUCA	19142	CALOTO
ALTO PATÍA Y NORTE DEL CAUCA	19	CAUCA	19212	CORINTO
ALTO PATÍA Y NORTE DEL CAUCA	19	CAUCA	19256	EL TAMBO
ALTO PATÍA Y NORTE DEL CAUCA	19	CAUCA	19364	JAMBALÓ
ALTO PATÍA Y NORTE DEL CAUCA	19	CAUCA	19450	MERCADERES
ALTO PATÍA Y NORTE DEL CAUCA	19	CAUCA	19455	MIRANDA
ALTO PATÍA Y NORTE DEL CAUCA	19	CAUCA	19473	MORALES
ALTO PATÍA Y NORTE DEL CAUCA	19	CAUCA	19532	PATÍA
ALTO PATÍA Y NORTE DEL CAUCA	19	CAUCA	19548	PIENDAMÓ
ALTO PATÍA Y NORTE DEL CAUCA	19	CAUCA	19698	SANTANDER DE QUILICHAO
ALTO PATÍA Y NORTE DEL CAUCA	19	CAUCA	19780	SUÁREZ

Con el script filtrar_pdet.py, que se puede encontrar en el repositorio de GitHub del equipo, se cruzó el listado en Excel con el GeoJSON del DANE a partir del código de cinco dígitos del municipio. El Excel contenía 170 filas y 170 municipios PDET únicos. El cruce encontró 170 municipios, con 170 códigos únicos y ningún municipio sin geometría, de modo que la integración fue completa. El script generó dos archivos: municipios_pdet.geojson, con los municipios filtrados, y municipios_pdet_mongodb.json, que contiene los 170 documentos preparados para su carga en MongoDB.

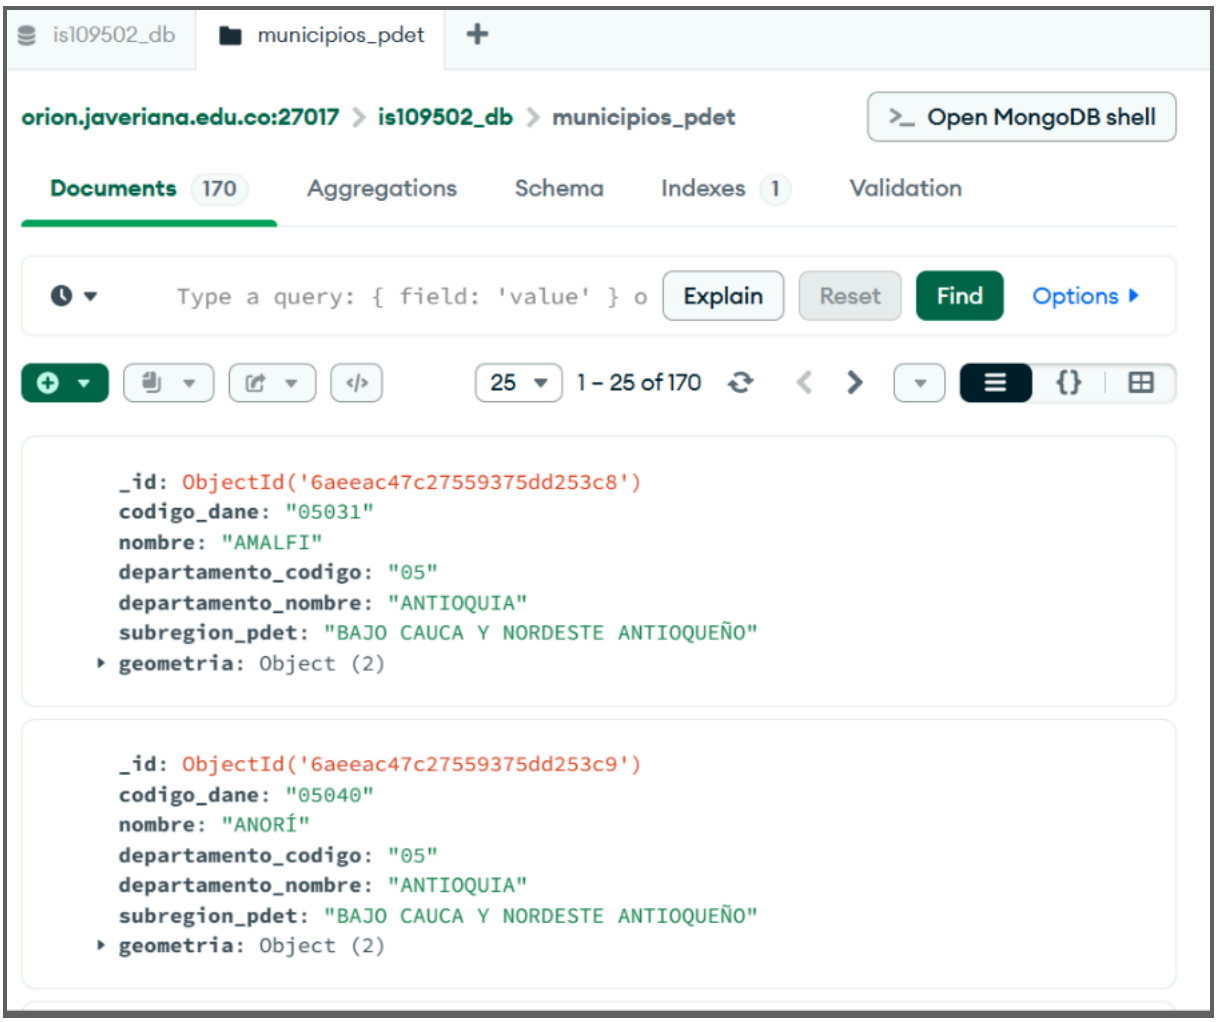
```
PS C:\Users\Administrador\PUJ2630\DBA\datos_proyecto\scripts> python .\filtrar_pdet.py
Filas en Excel: 170
Municipios PDET únicos: 170

--- RESULTADOS ---
Municipios encontrados: 170
Códigos únicos: 170
Municipios sin geometría: 0

Archivo generado: ../mgn/municipios_pdet.geojson
Integración completada correctamente.

Archivo para MongoDB generado: ../mgn/municipios_pdet_mongodb.json
Documentos preparados: 170
```

El archivo municipios_pdet_mongodb.json se importó en la base de datos is109502_db, alojada en el servidor entregado por la universidad, dentro de la colección municipios_pdet. En MongoDB Compass se verificó que la colección contiene 170 documentos, es decir, la totalidad de los municipios PDET. Cada documento incluye los campos codigo_dane, nombre, departamento_codigo, departamento_nombre, subregion_pdet y geometria. Antes de crear los índices la colección contaba únicamente con uno, el que MongoDB define por defecto sobre id.



Sobre la colección se crearon dos índices. El primero se definió sobre codigo_dane con la propiedad de unicidad. Esta configuración agiliza la búsqueda de un municipio por su código e impide insertar registros con códigos duplicados, lo que preserva la integridad de la información. El segundo es un índice espacial de tipo 2dsphere sobre el campo geometria. Este índice permite ejecutar consultas geoespaciales sobre los límites municipales, por ejemplo, determinar si un punto se encuentra dentro de un territorio. Su importancia para el proyecto radica en que permitirá asociar posteriormente las edificaciones de los conjuntos de datos seleccionados con sus respectivos municipios PDET.

La figura presenta los índices de la colección una vez creados. El índice id, con 36,9 kB, y el índice codigo_dane_1, con 20,5 kB, son de tipo regular y tienen la propiedad de unicidad. El índice geometria_2dsphere, con 65,5 kB, es de tipo geoespacial. Los tres se encuentran en estado listos, lo que indica que están construidos y disponibles para su uso.

Name & Definition	Type	Size	Usage	Avg. rate of usage	Properties	Status
_id_	REGULAR	36.9 kB	Usage data unavailable	Rate unavailable	UNIQUE	READY
codigo_dane_1	REGULAR	20.5 kB	Usage data unavailable	Rate unavailable	UNIQUE	READY
geometria_2dsphere	GEOSPATIAL	65.5 kB	Usage data unavailable	Rate unavailable		READY

Para comprobar que el índice espacial funciona, se ejecutó en MongoDB Compass una consulta con el operador $geoIntersects. Esta busca el documento cuya geometría intersecta un punto de coordenadas [-76,728; 8,093], expresadas en el orden longitud y latitud propio de GeoJSON. La consulta devolvió un único documento, el del municipio de Turbo (código 05837), del departamento de Antioquia y perteneciente a la subregión PDET Urabá Antioqueñ. Este resultado confirma que la colección permite identificar a qué municipio PDET pertenece un punto del territorio, que es la operación sobre la que se apoyará la asignación de edificaciones a municipios en los siguientes entregables.



5. Conclusiones Entrega 2

El entregable estableció la base espacial sobre la cual se desarrollarán las fases siguientes del proyecto. Los límites de los 170 municipios PDET se obtuvieron del MGN 2025 del DANE y se cruzaron con el listado oficial mediante el código de cinco dígitos del municipio. El cruce fue completo: se encontraron los 170 municipios, con 170 códigos únicos y ninguno sin geometría. Esto garantiza que el área de estudio esté definida de manera íntegra y sin ambigüedades.

Los dos conjuntos de edificaciones se redujeron a la zona de interés por mecanismos distintos, ambos necesarios por el volumen de los datos originales. En Google Open Buildings se extrajo el subconjunto de Colombia, que contiene 16.530.628 registros, y de ellos 2.223.614 corresponden a los municipios PDET, es decir, cerca del 13,5 % del total nacional. En GlobalBuildingAtlas, que no admite un filtrado directo, se cruzó la cuadrícula de teselas con los polígonos municipales mediante una intersección espacial, lo que permitió seleccionar únicamente las teselas que intersectan la zona de estudio y reducir de forma considerable el volumen de datos por descargar. La auditoría posterior de ambos conjuntos no encontró errores de formato ni valores nulos que requirieran depuración o imputación, por lo que los datos quedan aptos para su carga en MongoDB.

En cuanto a la integración NoSQL, la colección municipios_pdet contiene los 170 documentos y cuenta con tres índices en estado listo: el índice por defecto sobre _id, un índice único sobre codigo_dane y un índice espacial 2dsphere sobre geometria. El índice único impide registros duplicados y acelera la búsqueda por código, mientras que el índice espacial habilita las consultas geográficas. Su funcionamiento se verificó con una consulta $geoIntersects, que ubicó correctamente el punto de coordenadas [-76,728; 8,093] en el municipio de Turbo, Antioquia. Esta capacidad de identificar el municipio al que pertenece un punto es la operación en la que se apoyará la asignación de edificaciones a municipios en los siguientes entregables.